presentes no catálogo. O sistema seleciona as 20 músicas mais próximas aos cinco gêneros mais consumidos pelo usuário.

$$\text{similaridade}(x, y) = cos(\theta) = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2}\sqrt{\sum_i y_i^2}} \tag{1}$$

3.4. Método de Filtragem de Conteúdo baseado em Agentes Inteligentes

O processo de recomendação foi conduzido por meio de agentes inteligentes baseados em LLMs, implementados com a ajuda do framework CrewAI [CrewAI 2025], que permite a criação de arquiteturas multiagente colaborativas. Nesse contexto, agentes inteligentes podem ser compreendidos como programas que utilizam técnicas de inteligência artificial para executar tarefas que normalmente exigiriam intervenção humana [Russell and Norvig 2022], sendo capazes de operar de forma autônoma e adaptativa.

Ao invés de um único *prompt* genérico, a recomendação foi dividida em subtarefas executadas por agentes especializados, cada um com objetivos bem definidos como, por exemplo:

- **ReadingAgt**: Leitura e compreensão do catálogo musical;
- **AnalistAgt**: Análise do histórico de reprodução do usuário;
- **ExtractAgt**: Extração de padrões de preferência com base em gêneros e artistas;
- **RecommendAgt**: Geração da lista final de recomendações.

Esses agentes foram configurados para atuar de forma independente, mas colaborativa, compartilhando informações intermediárias. Toda comunicação entre os agentes e a base de dados foi realizada via APIs REST, garantindo reprodutibilidade e modularidade no processo, conforme a Figura 1.

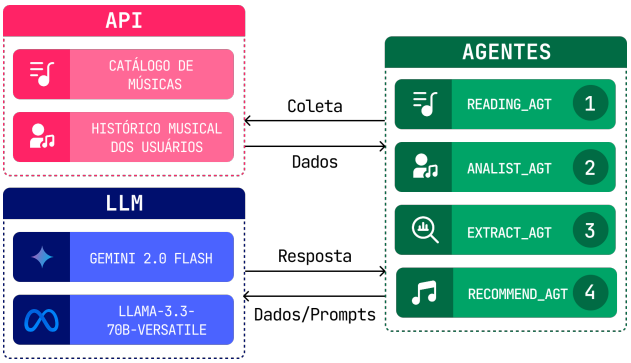

Figura 1. Fluxo do sistema de recomendação proposto

3.4.1. Especificação dos Agentes e *Prompts*

Os *prompts* empregados nos agentes seguem a abordagem *zero-shot*, na qual os modelos de linguagem realizam inferências diretamente, sem a necessidade de exemplos explícitos no próprio *prompt*. Esse tipo de configuração busca avaliar a capacidade dos LLMs em gerar recomendações com base na descrição textual do histórico musical do usuário e do catálogo de faixas disponíveis [Sun et al. 2019, Vagliano et al. 2018].

Nas tabelas de 2 a 4, são apresentados os *prompts* utilizados na construção dos agentes, bem como as ferramentas e tarefas atribuídas a cada um. A Tabela 2 apresenta as ferramentas utilizadas pelos agentes **ReadingAgt** e **AnalistAgt**, respectivamente. Essas ferramentas foram desenvolvidas utilizando o *CrewAI Tools* [CrewAI 2025] e consistem em funções que realizam requisições à API, permitindo o retorno dos dados necessários para os agentes.

Tabela 2. Ferramentas utilizadas e suas respectivas descrições

Ferramenta	Descrição
`GetUserHistory DataTool`	*Fetches the music data from a given URL and returns it as a list of dictionaries.*
`GetMusicCatalogue Tool`	*Fetches the user listening history from a given URL and returns the first 30 items as a list.*

A Tabela 3 apresenta os agentes previamente introduzidos, acompanhados de suas respectivas descrições de objetivo e contexto. A descrição de objetivo serve como diretriz principal, orientando as decisões e ações de cada agente ao longo do processo de recomendação. O contexto fornece informações adicionais que moldam a personalidade, o comportamento e a forma de atuação dos agentes [CrewAI 2025].

Tabela 3. Agentes utilizados, objetivos e ferramentas associadas

Agente	Objetivo (Goal)	Contexto (Backstory)	Ferramenta (Tool)
`ReadingAgt`	*Read all the songs from a catalogue.*	*Specializes in handling and returning a song catalogue.*	`GetMusic CatalogueTool`
`AnalistAgt`	*Read all a music history from an user.*	*Specializes in handling and returning a music history.*	`GetUserHistory DataTool`
`ExtractAgt`	*Inferring the user's favorite music genre.*	*Specializes in analysing the user music history to infer their 5 favorite music genres.*	-
`RecommendAgt`	*Recommend songs to a user using their listening histories.*	*You are a personalized music recommender. You analyze song genres and recommend tracks using content-based filtering techniques.*	-

A Tabela 4 apresenta a estruturação dos *prompts* utilizados nas tarefas, organizados de forma a guiar a execução passo a passo do processo de recomendação. Essa organização visa garantir clareza, coesão e eficiência na atuação de cada agente dentro do sistema. As tarefas, por sua vez, correspondem a atribuições específicas designadas aos agentes, contendo todas as informações necessárias para sua execução, como uma descrição detalhada, o agente responsável, as ferramentas requeridas, entre outros elementos essenciais que viabilizam a correta execução das ações [CrewAI 2025].

3.4.2. Seleção dos Modelos

Para a implementação do sistema de recomendação com agentes baseados em LLMs, a seleção dos modelos subjacentes foi guiada por critérios de capacidade técnica e viabilidade operacional, especialmente no contexto de acesso e custo. Foram avaliados o Gemini 2.0 Flash [Google 2025] e o LLaMA-3.3-70B-VERSATILE [Groq 2025] como os LLMs principais para as inferências dos agentes.

Tabela 4. Tarefas utilizadas no sistema

Descrição	Agente	Saída Esperada
Read and return all the song catalogue at this URL: `/getAllDataEniac?limit=300`.	`Song Catalogue Reader`	*Song Catalogue*
Read and return the user music history at this URL: `/getUserData/{user_id}`	`User Music History Reader`	*User listening history*
Infer the user's favorite music genres. Use the user's listening history to identify their 5 most preferred music genres.	`User Music Genres`	*User Music Genres*
Generate a list of 20 recommended songs from the catalogue. Use the user's listening history and inferred genres to build a personalized profile. Select songs that match the user's musical preferences. Return a JSON list with `genre`*,* `song_name` *and* `artist_name`*, along with* `liked` *and* `known` *flags.*	`Content-Based Music Recommender`	*Recommended Songs for the user*

O Gemini 2.0 Flash foi escolhido principalmente devido à sua capacidade de processar um elevado número de *tokens* em sua versão gratuita, oferecendo uma janela de contexto de até 1 milhão de *tokens*. Essa característica se mostrou decisiva para o projeto, pois permitiu o processamento de catálogos musicais extensos e históricos de reprodução detalhados dos usuários sem incorrer em custos adicionais significativos durante a fase de desenvolvimento e experimentação.

O modelo LLaMA-3.3-70B-VERSATILE foi escolhido devido à sua facilidade de acesso e custo-benefício através do serviço sob demanda da plataforma *Groq*, na qual permite o uso de LLMs aceleradas por meio de acesso de API [Groq 2025]. Apesar de não apresentar uma janela de *tokens* tão elevada quanto a versão gratuita do Gemini Flash, o custo acessível do serviço viabilizou a utilização de um modelo de grande porte (70 bilhões de parâmetros) para as operações de inferência mais complexas como, por exemplo, a análise de histórico e a inferência de padrões de preferência. A escolha de um modelo com 70B de parâmetros subentende a busca por uma maior capacidade de compreensão e geração de linguagem natural, permitindo aos agentes capturar nuances contextuais e semânticas mais profundas necessárias para uma recomendação musical sofisticada, mesmo que a velocidade e o custo tenham sido fatores mais diretos na decisão de acesso via *Groq*.

Ambos os modelos foram acessados por meio de chaves de API, o Gemini foi acessado via API proprietária, enquanto o LLaMA foi acessado via serviço sob demanda oferecido pela plataforma *Groq*.

3.5. Método de Avaliação

Foi desenvolvida uma interface específica para que os usuários interagissem com as *playlists* geradas pelos diferentes métodos de recomendação. Cada participante teve acesso às três *playlists*, compostas com 10 faixas recomendadas, correspondentes aos métodos avaliados (tradicional, LLaMA e Gemini), de forma cega, e realizou a avaliação de cada uma individualmente. A análise foi conduzida com base nos seguintes critérios:

1. Se gostou da música recomendada (resposta binária: Gostei / Não gostei);
2. Se já conhecia a faixa apresentada (resposta binária: Sim / Não);

3. Avaliação geral da *playlist*, em uma escala ordinal de 0 a 10, sendo 0 equivalente a ”péssimo”e 10 a ”ótimo”.

Com as respostas coletadas, são calculadas as seguintes métricas de avaliação, as quais serão usadas para comparação de desempenho dos diferentes modelos na tarefa de recomendação de músicas.

Taxa de Apreciação (*Like Rate*). Define-se como a proporção de músicas curtidas pelo usuário:

$$\text{LR} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}(\text{like}_i = 1) \tag{2}$$

onde N é o número total de músicas avaliadas pelo usuário na *playlist*, e $\mathbb{I}$ é a função indicadora.

Taxa de Descoberta (*Novelty Rate*). Corresponde à fração de músicas não previamente conhecidas pelo usuário:

$$\text{NR} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}(\text{known}_i = 0) \tag{3}$$

Taxa de Descobertas Bem-Sucedidas (*Successful Novelty Rate*). Proporção de músicas *novas* que foram curtidas, refletindo a eficácia da recomendação de faixas inéditas:

$$\text{SNR} = \frac{\sum_{i=1}^{N} \mathbb{I}(\text{known}_i = 0 \wedge \text{like}_i = 1)}{\sum_{i=1}^{N} \mathbb{I}(\text{known}_i = 0)} \tag{4}$$

Essa métrica é condicional à existência de pelo menos uma música nova na *playlist*.

Nota da Playlist (*Playlist Rating*). Refere-se à nota atribuída pelo usuário à *playlist* como um todo, após ouvir as dez faixas. Essa é uma medida subjetiva global da qualidade percebida da recomendação.

As métricas descritas permitem avaliar não apenas a eficácia da recomendação em termos de apreciação geral, mas também sua capacidade de promover descobertas relevantes aos usuários.

4. Resultados e Discussão

Os experimentos seguiram o protocolo descrito na Seção 3. A Tabela 5 e a Figura 2 apresentam os resultados médios das avaliações feitas por dez usuários, de forma cega, expressos em termos de média e desvio padrão. Considerando exclusivamente a métrica